Estruturação de dados do DOU

Tomás Barcellos

22 de maio de 2018

Caminho

- 1. O problema
- 2. A solução proposta
- 3. Os resultados alcançados

O Problema

A fonte

O Diário Oficial da União (DOU) é importante fonte de informações oficiais consultadas por diversos atores sociais. A informações publicadas no DOU são publicadas em formato de textos, tabelas e imagens: dados não-estrturados.

A fonte



Os desafios

- Até dezemebro 2017 a Imprensa Nacional disponibilizada o DOU somente em PDF.
- ▶ A partir de dezembro de 2017 o DOU passa a ser publicado também em HTML (com erros).
- ► Falta de padronização dos textos publicados

Os desafios



A solução proposta

Proposta: um pacote R

- 1. Em linha com os principios do tidyverse
- 2. Usar regex para identificar as informações publicadas

rdou: Etapas de processamento

O seguinte fluxo de trabalho foi adotado:

- 1. Download de todos as páginas do DOU (PDF) do dia;
- 2. Conversão dos PDFs em TXTs pelo Word;
- 3. Processamento dos arquivos TXT para estruturar a informação; e
- 4. Validação humana da informação processada.

rdou: download

```
# devtools::install_github("tomasbarcellos/rdou")
library(rdou)
download_dou("02/03/2017", dest_dir = "pdf")
```

A função download_dou() faz o download das páginas do DOU, em PDF. A função é chamada pelo seu efeito colateral (baixar) e retorna a data (invisível).

rdou: conversão

```
paginas <- converter_pdf(
  data = "02/03/2017", secao = 1,
  dir_pdf = "pdf", dest_dir = "txt"
)</pre>
```

A função converter_pdf() faz a conversão das páginas do DOU de PDF para TXT. A função é chamada pelo seu efeito colateral e retorna um vetor com o nome dos arquivos TXT criados (invisível).

rdou: processamento

List of 4

```
agric <- extrair_normas(paginas, "Agricultura")</pre>
faz <- extrair_normas(paginas, "Fazenda")</pre>
str(agric, give.attr = FALSE, vec.len = 1)
```

```
## $ : chr [1:5] "PORTARIA Nº 27, DE 21 DE FEVEREIRO DE 20
## $ : chr [1:5] "RESOLUÇÃO Nº 2, DE 24 DE FEVEREIRO DE 20
```

\$: chr [1:12] "RETIFICAÇÃO" ...

\$: chr [1:7] "PORTARIA Nº 46, DE 21 DE FEVEREIRO DE 20

rdou: processamento

```
# Objetos "norma" possuem alguns atributos
str(attributes(faz), vec.len = 1)
## List of 7
##
   $ class
               : chr "norma"
                  : chr [1:22] "SUPERINTENDÊNCIA DE NORMAS
##
   $ orgao
##
   $ arquivos
                  : chr [1:19] "inst/doc/txt/DOU1/2017/max
##
   $ data_dou
                  : Date[1:1], format: "2017-03-02"
##
   $ secao
                  : num 1
   $ encodificacao: chr "latin1"
##
    $ orgao_alvo : chr "Ministério da Fazenda"
##
```

rdou: estruturação das informações

```
df agric <- estruturar normas(agric)</pre>
dplyr::glimpse(df agric)
## Observations: 4
## Variables: 9
## $ numero
                 <int> 27. 2. NA. 46
                 <chr> "PORTARIA", "RESOLUÇÃO", "AVISO DE 1
## $ tipo
                 <chr> "SECRETARIA DE DEFESA AGROPECUÁRIA"
## $ orgao
                 <chr> "PORTARIA Nº 27, DE 21 DE FEVEREIRO
## $ texto
## $ promulgacao <date> 2017-03-02, 2017-03-02, 2017-03-02
                 <chr> "Credencia a empresa DÍGITOS CERTIF"
## $ ementa
## $ titulo
                 <chr> "PORTARIA Nº 27, DE 21 DE FEVEREIRO
## $ pagina
                 \langle int \rangle 5, 5, 6, 6
## $ secao
                 <int> 1, 1, 1, 1
```

Usando o pipe

```
library(magrittr)
download_dou("02/03/2017") %>%
  converter_pdf(secao = 1) %>%
  pegar_normas_dou(orgao_alvo = "Agricultura") %>%
  estruturar_normas()
```

Resultados

Resultados

- Mais de 13.705 normas encontradas entre os meses de abril de 2015 e dezembro de 2017 nas seções 1 e 2 do DOU para o Ministério da Agricultura, Pecuária e Abastecimento.
- Alimentação semi-automatizada do Sistemas de Consulta a Legislação Agropecuária.