Desmistificando Big Data: é possível manipular grandes bases de dados em R?

Samuel Macêdo

Definindo Big Data

- Volume
- Velocidade
- Variedade
- Veracidade
- Valor

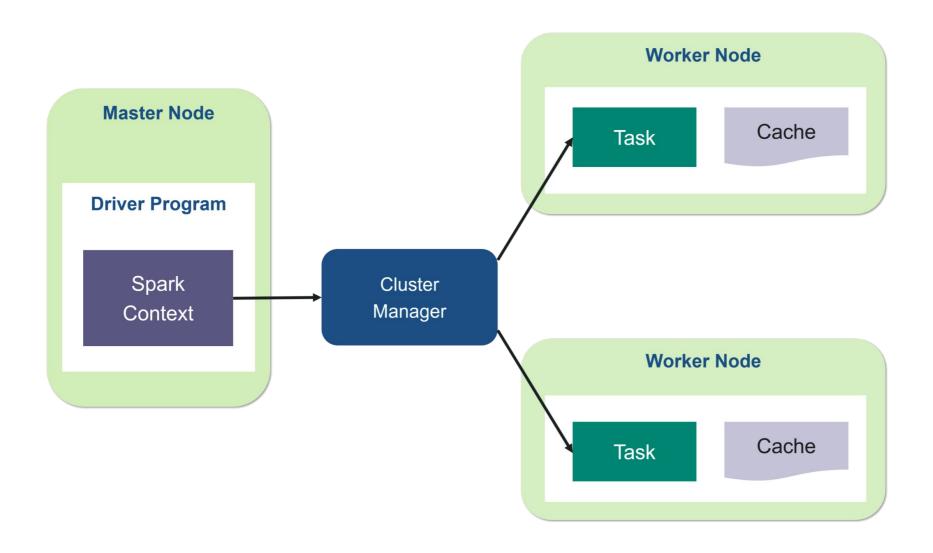
Definindo Big Data

- Veracidade
- Valor
- Volume

Quem processa Big Data?



Arquitetura



Como funciona o R?





















R roda Big Data?

Claro que NÃO

É possível trabalhar com Big Data em R?

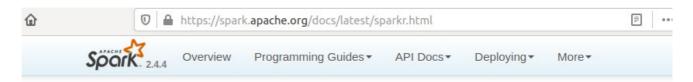
Definitivamente SIM

E qual mágica?



Pacotes em R

- SparkR

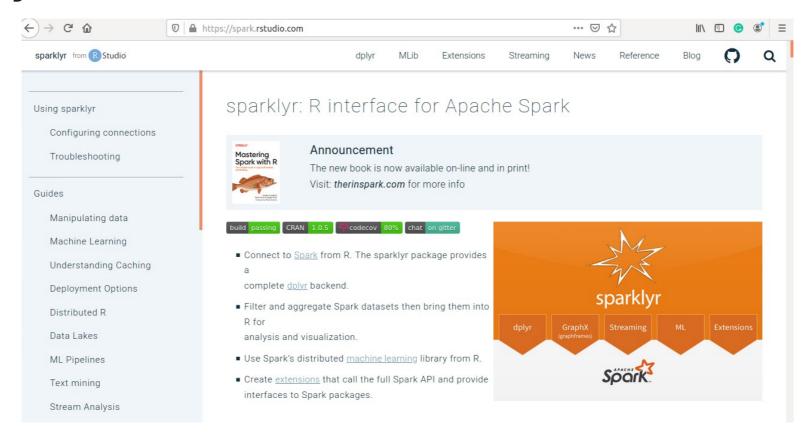


SparkR (R on Spark)

- Overview
- SparkDataFrame
 - · Starting Up: SparkSession
 - · Starting Up from RStudio
 - Creating SparkDataFrames
 - From local data frames
 - From Data Sources
 - From Hive tables
 - SparkDataFrame Operations
 - Selecting rows, columns
 - Grouping, Aggregation
 - Operating on Columns
 - Applying User-Defined Function
 - Run a given function on a large dataset using dapply or dapplyCollect
 - dapply
 - dapplyCollect
 - Run a given function on a large dataset grouping by input column(s) and using gapply or gapplyCollect
 - gapply
 - gapplyCollect
 - Run local R functions distributed using spark.lapply
 - spark.lapply
 - · Running SQL Queries from SparkR
- Machine Learning
 - Algorithms
 - Classification
 - Degression

Pacotes em R

- sparklyr

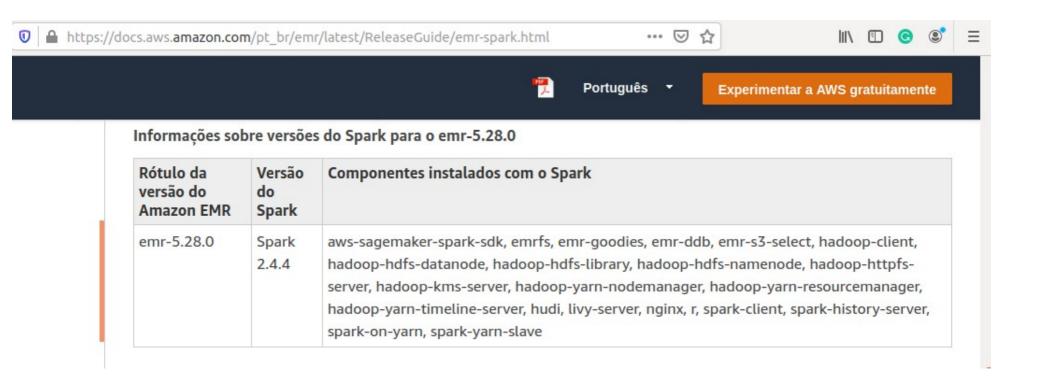


Invoke

```
\\ scala
package au.csiro.variantspark.api
class VSContext(val spark:SparkSession) {...}
\\ r
sparklyr::invoke_new(sc,
"au.csiro.variantspark.api.VSContext", spark_session(sc))
```

Configuração

sparklyr::spark_install()



Eu preciso do R?









E porque R?

- Fácil
- Concentrado
- Aprender uma linguagem

Quando eu devo usar spark?

- Use o R sempre que possível!!!
- Spark em versão local
- Spark em cloud

Resumo

- Trate bem seus dados
- R como interface para o spark
- Só use spark quando realmente precisar

- E o principal...

É possível trabalhar em Big Data com R!!!

Contatos

- samuelmacedo@recife.ifpe.edu.br
- github.com/samuelmacedo83